

UNIVERSIDADE FEDERAL DE SANTA MARIA  
CENTRO DE TECNOLOGIA  
CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

Lorenzo Moreira Donatti

**APLICAÇÃO DE ALGORITMOS DE APRENDIZADO DE MÁQUINA  
PARA A DEMODULAÇÃO DE SINAIS DE COMUNICAÇÃO POR LUZ  
VISÍVEL**

Santa Maria, RS  
2023

Lorenzo Moreira Donatti

**APLICAÇÃO DE ALGORITMOS DE APRENDIZADO DE MÁQUINA PARA A  
DEMODULAÇÃO DE SINAIS DE COMUNICAÇÃO POR LUZ VISÍVEL**

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia de Computação da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Bacharel em Engenharia de Computação**. Defesa realizada por videoconferência.

Orientador: Prof. Carlos Henrique Barriquello

Santa Maria, RS  
2023

**Lorenzo Moreira Donatti**

**APLICAÇÃO DE ALGORITMOS DE APRENDIZADO DE MÁQUINA PARA A  
DEMODULAÇÃO DE SINAIS DE COMUNICAÇÃO POR LUZ VISÍVEL**

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia de Computação da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Bacharel em Engenharia de Computação**.

**Aprovado em 10 de fevereiro de 2023:**

---

**Carlos Henrique Barriquello, Dr. (UFSM)**  
**(Presidente/Orientador)**

---

**Leonardo Ramos Emmendorfer, Dr. (UFSM) (videoconferência)**

---

**Rosane Beatriz Oliveira Severo, Dr. (UFSM) (videoconferência)**

Santa Maria, RS  
2023

## RESUMO

# APLICAÇÃO DE ALGORITMOS DE APRENDIZADO DE MÁQUINA PARA A DEMODULAÇÃO DE SINAIS DE COMUNICAÇÃO POR LUZ VISÍVEL

AUTOR: Lorenzo Moreira Donatti  
Orientador: Carlos Henrique Barriquello

Com o exponencial avanço da tecnologia, a quantidade e a complexidade dos dados disponíveis estão cada vez maiores. Esse fato se faz presente na área de transmissão e recepção de dados. Com isso, Algoritmos de aprendizado de máquina vêm ganhando relevância como uma das diversas possíveis soluções na área de Telecomunicações para a demodulação de sinais. Neste trabalho será proposto um método composto de três etapas para a criação de um demodulador de sinais *On-Off Keying (OOK)* de comunicação por luz visível, sendo elas: aquisição dos dados, pré-processamento e filtragem dos dados, criação e treinamento dos algoritmos de aprendizado de máquina. Os dados foram obtidos em um conjunto de dados públicos disponibilizado por Ma et al. (2019), composto por diversas modulações vindas de um sistema de comunicação por luz visível que varia a distância do receptor e do emissor entre 0 cm e 180 cm. Os dados passarão por uma filtragem através de um filtro gaussiano, além de separados em duas abordagens, sendo elas: Implementar um modelo de aprendizado de máquina para cada distância, fazendo o uso de vários modelos, e implementar apenas um modelo de aprendizado de máquina para todas as distâncias, transformando em uma abordagem geral. Os algoritmos de aprendizado de máquina abordados serão: árvores de decisão, métodos ensemble via *bagging* e *boosting*. A métrica utilizada será a acurácia dos modelos. Os algoritmos *Random Forest* e *Gradient Boosting* obtiveram as melhores acurácias, em ambos os casos. Além disso, o uso do filtro apresentou uma melhora da acurácia em ambas abordagens. Por fim, verificou-se que a abordagem de criar um modelo de aprendizado de máquina para cada distância gera melhores acurácias que a abordagem de propósito geral.

**Palavras-chave:** Aprendizado de Máquina. Modulação *On-Off Keying*. Comunicação por Luz Visível. *Ensemble*.

## **ABSTRACT**

### **MACHINE LEARNING ALGORITHMS FOR SIGNAL DEMODULATION IN VISIBLE LIGHT COMMUNICATIONS**

**AUTHOR:** Lorenzo Moreira Donatti  
**ADVISOR:** Carlos Henrique Barriquello

Due to the exponential technology advance, the amount of data and its complexity are becoming higher. Thus, the use of Machine Learning become interesting in telecommunications area to signal demodulation. This work propose a method made by three steps to develop a machine learning based OOK demodulator to visible light communication. These three steps are: data acquisition, pre-processing, building and training machine learning algorithms. Data was acquired by a public dataset developed by Ma et al. (2019), having multiple modulations in a visible light communication system varying the distance between emitter and receptor by 0 cm to 180 cm. Data will be filtered by a level three gaussian filter and splitted by two approaches: A machine learning model for each distance, creating multiple specific models, and an unique machine learning model for all dataset, creating a general purpose approach. The used machine learning algorithms are: Decision trees, bagging and boosting ensemble methods. The metric used is model accuracy. Random Forest and Gradient Boosting had the best accuracies in both approaches, furthermore, filter also presented an accuracy gain in both approaches. Finally, specific models approach get better results than the general purpose approach.

**Keywords:** Machine Learning. On-Off Keying modulation. Visible Light Communication. Ensemble.

## LISTA DE FIGURAS

FIGURA 1 – Datas marcantes na história do aprendizado de máquina. ....	9
FIGURA 2 – Exemplo de sistema VLC. ....	10
FIGURA 3 – Diagrama de contexto do trabalho. ....	11
FIGURA 4 – Sistema utilizado para obter os dados. ....	13
FIGURA 5 – Espectro Eletromagnético. ....	15
FIGURA 6 – Método de Bagging. ....	19
FIGURA 7 – Método de Boosting. ....	20
FIGURA 8 – Método proposto para o desenvolvimento do trabalho. ....	22

## LISTA DE GRÁFICOS

GRÁFICO 1 – Sinais na distância 0 cm e distância 140 cm. ....	24
GRÁFICO 2 – Sinais filtrados na distância 0 cm e distância 140 cm. ....	24
GRÁFICO 3 – Acurácia dos modelos com 40 amostras abordagem 1. ....	27
GRÁFICO 4 – Acurácia dos modelos com 80 amostras abordagem 1. ....	28
GRÁFICO 5 – Acurácia dos modelos com 40 amostras abordagem 2. ....	30
GRÁFICO 6 – Acurácia dos modelos com 80 amostras abordagem 2. ....	31

## LISTA DE TABELAS

TABELA 1 – Comparativo entre VLC e RF.....	16
TABELA 2 – Bibliotecas utilizadas.....	23
TABELA 3 – Hiper parâmetros dos algoritmos utilizados.....	26
TABELA 4 – Acurácia na distância 100 cm com 40 amostras abordagem 1.....	28
TABELA 5 – Acurácia na distância 100 cm com 80 amostras abordagem 1.....	28
TABELA 6 – Melhora na acurácia com 40 amostras abordagem 1.....	29
TABELA 7 – Melhora na acurácia com 80 amostras abordagem 1.....	29
TABELA 8 – Acurácia na distância 100 cm com 40 amostras abordagem 2.....	30
TABELA 9 – Acurácia na distância 100 cm com 80 amostras abordagem 2.....	31
TABELA 10 – Melhora na acurácia com 40 amostras abordagem 2.....	31
TABELA 11 – Melhora na acurácia com 80 amostras abordagem 2.....	32
TABELA 12 – Comparação das abordagens com o algoritmo <i>Random Forest</i> 40 amostras.....	32
TABELA 13 – Comparação das abordagens com o algoritmo <i>Gradient Boosting</i> 40 amostras.....	32
TABELA 14 – Comparação das abordagens com o algoritmo <i>Random Forest</i> 80 amostras.....	33
TABELA 15 – Comparação das abordagens com o algoritmo <i>Gradient Boosting</i> 80 amostras.....	33



## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO .....</b>	<b>9</b>
1.1	OBJETIVOS .....	11
1.1.1	Objetivos gerais .....	11
1.1.2	Objetivos específicos .....	12
1.2	METODOLOGIA .....	12
1.2.1	Escolha do conjunto de dados .....	12
1.2.2	Escolha do filtro .....	13
1.2.3	Escolha dos algoritmos .....	13
1.3	ESTRUTURA DO TRABALHO .....	14
<b>2</b>	<b>FUNDAMENTAÇÃO TEÓRICA .....</b>	<b>15</b>
2.1	COMUNICAÇÃO POR LUZ VISÍVEL .....	15
2.2	MODULAÇÃO DE SINAIS .....	16
2.2.1	On-Off Keying (OOK) .....	16
2.3	APRENDIZADO DE MÁQUINA .....	17
2.3.1	Aprendizado supervisionado .....	17
2.4	ÁRVORES DE DECISÃO .....	17
2.5	MÉTODOS DE <i>ENSEMBLE</i> .....	18
2.5.1	Bagging .....	18
2.5.2	Boosting .....	18
<b>3</b>	<b>TRABALHOS RELACIONADOS .....</b>	<b>21</b>
<b>4</b>	<b>MÉTODO PROPOSTO .....</b>	<b>22</b>
4.1	FERRAMENTAS UTILIZADAS .....	22
4.2	AQUISIÇÃO DOS DADOS .....	23
4.3	PRÉ-PROCESSAMENTO DOS DADOS .....	23
4.3.1	Verificação e conversão dos dados .....	23
4.3.2	Aplicação de filtros .....	24
4.3.3	Separação e divisão dos dados .....	25
4.4	CRIAÇÃO E TREINAMENTO DOS MODELOS .....	25
<b>5</b>	<b>RESULTADOS EXPERIMENTAIS .....</b>	<b>27</b>
5.1	RESULTADOS ABORDAGEM 1 .....	27
5.2	RESULTADOS ABORDAGEM 2 .....	29
5.3	DISCUSSÃO FINAL .....	32
<b>6</b>	<b>CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS .....</b>	<b>34</b>
	<b>REFERÊNCIAS BIBLIOGRÁFICAS .....</b>	<b>35</b>
	<b>APÊNDICE A – CÓDIGOS DESENVOLVIDOS .....</b>	<b>37</b>

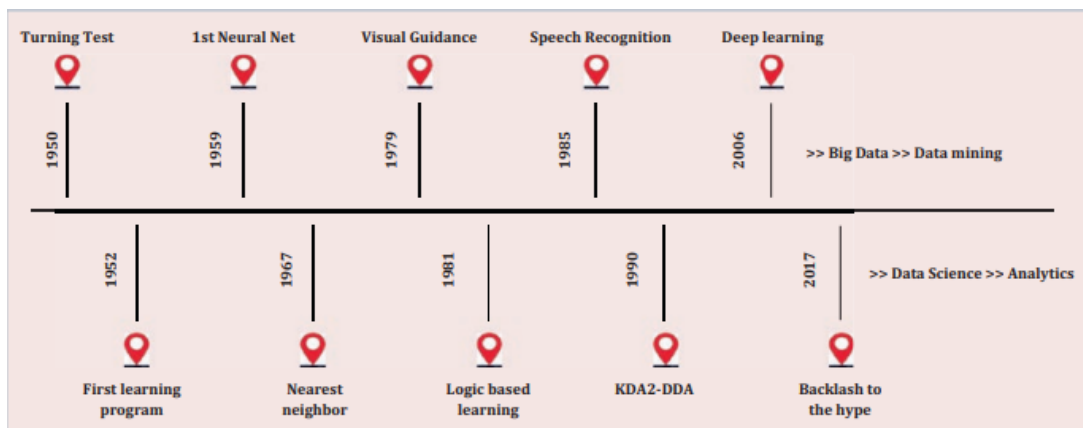
## 1 INTRODUÇÃO

Nas últimas décadas, devido ao exponencial avanço da computação, a transmissão digital de sinais tem ganhado cada vez mais espaço. Não é surpresa que grande parte das informações disponíveis são atualmente transmitidas de forma digital. Isso se deve ao fato que as transmissões digitais possuem menor custo, maior qualidade e capacidade, se comparadas com a transmissão analógica (CHEN, 2005).

Uma das formas de comunicação de dados que vem ganhando maior notoriedade recentemente é a comunicação por luz visível (VLC), de acordo com Chi et al. (2020), por ser considerada uma comunicação de alta velocidade, pode se tornar uma parte crucial da rede de sexta geração (6G). A comunicação por luz visível oferece diversas vantagens se comparada com a comunicação por rádio frequência, como uma maior taxa de dados, maior eficiência energética e melhor segurança (AMRAN et al., 2020).

Além disso, outra área que está em constante evolução, com o avanço do poder computacional, é o aprendizado de máquina. Hoje em dia, algoritmos de aprendizado de máquina conseguem ser executados em computadores pessoais, algo inimaginável décadas atrás. Exemplo disso, são os algoritmos que tentam replicar redes neurais biológicas. A figura 1 mostra que a primeira rede neural artificial é datada de 1959, porém devido a limitações computacionais, apenas em 2006 avanços significativos começaram a ocorrer.

Figura 1 – Datas marcantes na história do aprendizado de máquina.



Fonte: Adaptado de Nandi e Pal (2021).


Os algoritmos de aprendizado de máquina têm seu funcionamento pautado na qualidade dos dados inseridos, sendo eles um dos recursos mais importantes para esses algoritmos. Um dado pode ser considerado de qualidade quando ele satisfaz os requisitos necessários para seu uso, enquanto um dado sem qualidade não satisfaz estes requisitos. Além disso, dados são o combustível utilizados para a tomada de decisão (OLSON, 2003). Não à toa, os dados têm obtido grande popularidade neste século, sendo cha-

mados, inclusive, pelas grandes mídias, como na publicação feita por Kiran Bhageshpur (2019) na revista *Forbes*, de novo petróleo, dado sua tamanha importância. O trabalho Jain et al. (2020) demonstra e relata a importância de prezar por dados de qualidade antes de qualquer aplicação de aprendizado de máquina.

Diante disso, a área de transmissão e recepção de sinais é caracterizada pela geração de dados, abrindo um leque de possibilidades onde o aprendizado de máquina aparece como uma ferramenta de auxílio neste processo. Os autores Shi et al. (2020) introduzem o conceito de comunicação inteligente, onde algoritmos de aprendizado de máquina recebem os dados de um transmissor já rotulados a fim de encontrar padrões e generalizar sua saída, diferente da comunicação convencional, onde a saída se dá por fórmulas pré-definidas e de difícil flexibilização, a desvantagem desta abordagem inteligente se dá pela dependência do número de dados gerados, podendo obter baixas acurácias se o conjunto não for grande o suficiente.

A figura 2 apresenta todas as etapas necessárias em um sistema convencional de comunicação por luz visível. A comunicação inteligente se diferencia na etapa da modulação e demodulação, onde os algoritmos de aprendizado de máquina são inseridos, porém, neste trabalho será abordada apenas a demodulação.

Figura 2 – Exemplo de sistema VLC.



Fonte: Adaptado de (YI; LEE, 2014).

Para um melhor entendimento, a figura 3 é um diagrama de contexto que exemplifica as etapas presentes na demodulação de uma comunicação inteligente, grande parte delas também desenvolvidas neste trabalho. O único bloco que não está presente neste trabalho são os algoritmos de Aprendizado profundo (*Deep Learning*), pois apenas técnicas de aprendizado de máquina (*Machine Learning*) foram escolhidas. Este diagrama visa a compreensão do ambiente e dos fatores críticos que podem afetar o projeto.

Figura 3 – Diagrama de contexto do trabalho.



Fonte: Próprio Autor.

## 1.1 OBJETIVOS

Esta seção tem como finalidade detalhar os objetivos gerais e específicos deste trabalho.

### 1.1.1 Objetivos gerais

O objetivo geral deste trabalho é implementar e verificar a viabilidade de demoduladores a base de algoritmos de aprendizado de máquina. Para isso, diversos dados modulados utilizando a modulação *On-off keying* (OOK), obtidos em um conjunto de dados público, disponibilizado por Ma et al. (2019) serão enviados para os algoritmos e sua acurácia será avaliada.

### 1.1.2 Objetivos específicos

Para a obtenção do objetivo geral, os seguintes objetivos específicos devem ser atingidos:

- Estudar e levantar as principais técnicas utilizadas na classificação de sinais modulados.
- Obter e pré-processar dados de comunicação por luz visível modulados pela modulação *OOK*.
- Desenvolver diferentes modelos de aprendizado de máquina.
- Validar e verificar a acurácia dos modelos nos dados modulados obtidos.

## 1.2 METODOLOGIA

A metodologia aplicada neste trabalho teve por início o levantamento bibliográfico sobre transmissão e recepção de sinais de comunicação por luz visível e sobre algoritmos de aprendizado de máquina supervisionados.

Este levantamento serviu como base e aprofundamento para as próximas etapas da metodologia, a concepção e o desenvolvimento do método proposto no capítulo 4. O método consiste em três etapas, sendo elas: aquisição dos dados, pré-processamento e filtragem, criação e treinamento dos algoritmos.

Por fim, os resultados obtidos com a aplicação do método proposto são discutidos e avaliados no capítulo 5.

### 1.2.1 Escolha do conjunto de dados

O conjunto de dados utilizado neste trabalho foi obtido em Ma et al. (2019). A escolha deste conjunto de dados se deve pelo fato de que segundo os próprios criadores Ma et al. (2019), este é um dos primeiros conjuntos de dados envolvendo modulação de sinais de comunicação por luz visível presentes na literatura.

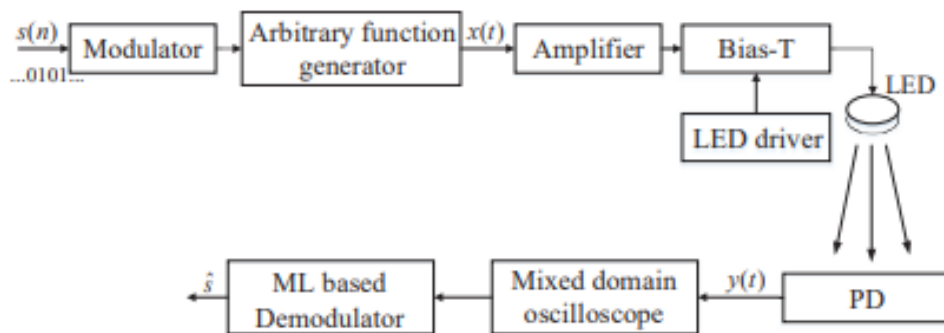
Este conjunto de dados consiste em dados recebidos de um sistema físico de comunicação por luz visível em oito diferentes modulações, sendo elas: *OOK*, *QPSK*, *4-PPM*, *16-QAM*, *32-QAM*, *64-QAM*, *128-QAM* e *256-QAM*. Neste trabalho será abordada apenas a modulação *OOK*.

Além disso, para cada modulação o número de amostras abrange quatro diferentes valores, sendo eles: 10, 20, 40 e 80 amostras por sinal enviado. Os dados estão rotulados

a partir do número de amostras, ou seja, para cada modulação existem quatro diferentes resultados. Ademais, os dados foram obtidos em diferentes distâncias, variadas de 0 cm a 180 cm do emissor, onde todas possuem os mesmos rótulos. Os dados estão normalizados e variam de 0 a 1.

A figura 4 mostra o sistema utilizado para a obtenção dos dados do conjunto Ma et al. (2019).

Figura 4 – Sistema utilizado para obter os dados.



Fonte: Retirado de Ma et al. (2019)

Comparando este sistema da figura 4 com o sistema convencional de comunicação por luz visível da figura 2, a principal diferença se encontra no demodulador, onde a classificação dos dados modulados deve ser realizada por algoritmos de aprendizado de máquina.

### 1.2.2 Escolha do filtro

Na tentativa de reduzir possíveis ruídos presentes no conjunto de dados, principalmente em maiores distâncias, foi escolhido a aplicação de um filtro. Após verificação na literatura, a exemplo de Ito e Xiong (2000), que propõem a aplicação de filtros gaussianos em problemas não lineares, o filtro gaussiano mostrou-se uma boa alternativa para a redução de ruído em diversas aplicações, incluindo comunicação de dados. Portanto, foi utilizado nos dados obtidos de comunicação por luz visível.

### 1.2.3 Escolha dos algoritmos

Foram utilizados quatro diferentes algoritmos para a criação dos demoduladores, sendo eles: árvores de decisão, *Random Forests*, *Gradient Boosting* e *Adaptative Boosting* (*AdaBoost*). Sendo que, os três últimos citados são formas de *ensemble*, ou seja,

algoritmos que consistem na combinação de classificadores fracos para a formação de um classificador forte, que obtém acurácia próxima de 100% (ROKACH, 2005). Os tipos de ensemble utilizados neste trabalho serão abordados com maior profundidade na seção 2.5.

O algoritmo utilizado como classificador fraco dos *ensembles* será a árvore de decisão, sua escolha ocorre pela ampla utilização em problemas de classificação, inclusive em problemas de demodulação de sinais (SHI et al., 2020). Além de sua simplicidade de visualização e entendimento, fator crucial na escolha do algoritmo.

A escolha dos diferentes métodos *ensembles*, como *Random Forests*, um tipo de *bagging*, e *Gradient Boosting* e *AdaBoost*, tipos de *boosting*, se deve ao fato de que segundo Rokach (2005), estes algoritmos, cuja propriedade é combinar preditores fracos, possuem um poder de generalização superior se comparados aos algoritmos fracos isolados. Além disso, em estudos empíricos de problemas de classificação, algoritmos de *bagging* possuem acurácia superior ao algoritmo base, enquanto o *boosting* alcança acurácias superiores ao *bagging*, porém pode sofrer *overfitting* em alguns casos (OPITZ; MACLIN, 1999).

### 1.3 ESTRUTURA DO TRABALHO

Este trabalho apresenta seis capítulos diferentes, sendo eles:

- O Capítulo 1 introduz o tema e a forma que ele será abordado neste trabalho.
- O Capítulo 2 fundamenta os conceitos mínimos para o entendimento dos métodos empregados neste trabalho.
- O Capítulo 3 apresenta uma revisão sobre trabalhos relacionados à demodulação de sinais *VLC* via algoritmos de aprendizado de máquina.
- O Capítulo 4 detalha o método proposto para o desenvolvimento deste trabalho.
- O Capítulo 5 relata os resultados obtidos com a aplicação do método proposto, implementado no capítulo anterior.
- O Capítulo 6 aborda comentários sobre os resultados obtidos, além de observações sobre possíveis implementações para trabalhos futuros.


## 2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo serão abordados os principais conceitos utilizados no desenvolvimento deste trabalho.

### 2.1 COMUNICAÇÃO POR LUZ VISÍVEL

A comunicação por luz visível é uma tecnologia de comunicação que utiliza a luz visível como meio para transmitir dados. Esta tecnologia funciona modulando a intensidade de uma fonte de luz para codificar informação e transmiti-lá para um receptor. Tipicamente diodos emissores de luz (*LEDs*) são utilizados como emissores, sendo sua eficiência e durabilidade considerados pontos fortes (NDJIONGUE; FERREIRA; NGATCHED, 2000). O espectro visível possui uma faixa de comprimento de onda de aproximadamente 380nm até 780nm, a figura 5 mostra com mais detalhes o espectro de frequência que a luz visível se encontra. Devido suas limitações nas distâncias de propagação devido os *LEDs*, é considerada, na maior parte dos casos, uma comunicação de curto alcance (NDJIONGUE; FERREIRA; NGATCHED, 2000).

Figura 5 – Espectro Eletromagnético.



Fonte: Retirado de (PATHAK P. H., 2015 apud MATHEUS et al., 2017).

Uma das principais vantagens do uso de *VLC* é que as lâmpadas utilizadas para iluminação podem ser reaproveitadas para a transmissão de dados. Além disso, como na sua maior parte, a comunicação se dá por curto alcance e apenas onde a luz está presente, diversas aplicações que necessitam de maior segurança podem se beneficiar desta tecnologia. Segundo Arnon (2015), duas aplicações emergentes são os sistemas de comunicação em transportes inteligentes e em hospitais.

Por fim, de acordo com Matheus et al. (2017), uma das maiores vantagens da luz como forma de comunicação é a alta frequência das ondas, na casa de THz, fato que possibilita grandes velocidades. Graças à alta frequência das ondas de luz, pesquisas com



VLC já obtiveram resultados extremamente expressivos, atingindo velocidades superiores a 100 Gbps.

A tabela 1 faz um comparativo entre a comunicação por luz visível e a comunicação por rádio frequência.

Tabela 1 – Comparativo entre VLC e RF.

	Radiofrequência	VLC
Espectro	300 GHz	400 THz
Infraestrutura	Ponto de acesso	Iluminação
Interferência e Ruídos	Baixa	Alta
Segurança	Limitada	Alta
Cobertura	Alta	Limitada
Complexidade do sistema	Alta	Baixa
Interferência Eletromagnética	Sim	Não

Fonte: Retirado de (IEEE, 2011 apud MATHEUS et al., 2017).

## 2.2 MODULAÇÃO DE SINAIS

### 2.2.1 On-Off Keying (OOK)

OOK é uma modulação de baixa complexidade. É considerada um caso especial da *amplitude shift keying* (ASK), que emprega dois níveis de tensão, onde o segundo é zero (NDJIONGUE; FERREIRA; NGATCHED, 2000). Por ser simples e de fácil aplicação, esta modulação está presente em diversos sistemas de comunicação. Porém, ela pode apresentar problemas quando aplicada a VLC. Segundo Ndjiongue, Ferreira e Ngatched (2000), quando dois valores iguais são recebidos em sequência, a modulação pode representar alterações nos valores de intensidade no LED, esse desbalanceamento pode ser prejudicial. Os autores Matheus et al. (2017) citam o exemplo de que caso o valor 100001 seja enviado, a lâmpada ficaria desligada por muito tempo, podendo causar oscilações perceptíveis aos olhos humanos. Para isso, medidas como a redefinição de níveis ON e OFF podem ser tomadas, ou seja, o bit 0 passa a ser representado por outra intensidade de luz.

## 2.3 APRENDIZADO DE MÁQUINA

Aprendizado de máquina (*Machine Learning*), é uma sub área da Inteligência Artificial que consiste no aprendizado e criação de regras por meio de dados.

Aprendizado de máquina é o campo de estudo que possibilita aos computadores a habilidade de aprender sem explicitamente programá-los (SAMUEL, 1959 apud GÉRON, 2019).

Um sistema de *Machine Learning* é treinado ao invés de explicitamente programado, exemplos são inseridos e através de padrões estatísticos nestes dados o sistema acha regras para automatizar a tarefa (CHOLLET, 2017).

### 2.3.1 Aprendizado supervisionado

Ocorre o aprendizado supervisionado quando o algoritmo de *Machine Learning* necessita de dados rotulados, ou seja, cada dado possui uma solução vinculada. O algoritmo passa por um período de treino nestes dados rotulados, onde seus parâmetros são ajustados com o intuito de prever novos dados, esse processo se chama generalização.

Segundo Praveena e Jaiganesh (2017), o aprendizado supervisionado passa por 5 etapas:

- Estabelecer o tipo dos dados de treinamento.
- Selecionar bons dados de treinamento, além de verificar se os rótulos estão compatíveis.
- Preparar os dados de entrada do modelo, pois estão altamente ligados com a acurácia.
- Preparar a estrutura e correto funcionamento da função de aprendizado.
- Entender o algoritmo e aplicá-lo nos dados de treinamento.
- Medir a acurácia e outras métricas do modelo, após, aplicar em dados de teste.

## 2.4 ÁRVORES DE DECISÃO

Árvores de decisão são algoritmos de aprendizado de máquina que podem executar diversas tarefas, principalmente as de classificação. São algoritmos capazes de se adaptar a conjunto de dados complexos, ainda que sejam intuitivas e de fácil interpretação. Isso

porque são capazes de combinar questões simples sobre os dados de uma forma entenedível, classificando os dados fazendo diversas perguntas sobre seus atributos, de forma hierárquica (KINGSFORD; SALZBERG, 2008).

Árvores de decisão possuem como propriedade a eficiência na execução, sendo um algoritmo de menor complexidade se comparado a grande maioria dos algoritmos de classificação (HARRISON, 2019).

## 2.5 MÉTODOS DE *ENSEMBLE*

### 2.5.1 Bagging

O *ensemble* por *bagging* consiste na formação de diferentes subconjuntos aleatórios no conjunto de treinamento, aplicados a um único algoritmo, gerando diversos preditores. Segundo Géron (2019), em problemas de classificação, geralmente a moda destes preditores gera a predição final. A vantagem deste *ensemble* é que todos os preditores podem facilmente treinar em paralelo.

Quando um grupo de árvores de decisão é treinado em *bagging*, esse *ensemble* passa a se chamar floresta aleatória. Segundo Harrison (2019) esse é um dos algoritmos mais poderosos disponíveis.

Ao adicionar novas árvores, florestas aleatórias não sofrem de *overfitting*, apenas podem chegar a um valor limite de erro (BREIMAN, 2001).


### 2.5.2 Boosting

*Boosting* refere-se a qualquer método *ensemble* que combine preditores fracos formando um preditor forte. Os métodos de *boosting* geralmente consistem no treinamento sequencial dos preditores fracos, buscando corrigir seu predecessor (GÉRON, 2019). Pelo fato de serem sequenciais, o treinamento em paralelo fica dificultado.

Segundo Géron (2019), os preditores mais populares e com potencial de alcançar maiores acurácias são o *AdaBoost* e o *Gradient Boosting*.

*AdaBoost* é o método de *boosting* que reajusta as instâncias de treinamento do preditor antecessor. Fazendo que para cada novo preditor, as instâncias classificadas erroneamente pelo antecessor ganhem um peso maior. Segundo Géron (2019), esse processo faz com que o algoritmo se assemelhe com o gradiente descendente, porém ao invés de ajustar parâmetros de um único preditor para minimizar uma função de custo, o *AdaBoost* adiciona preditores ao conjunto melhorando gradualmente as fronteiras de decisão.


Figura 6 – Método de Bagging.



Fonte: Adaptado de (Gaurav Singhal, 2020)

De forma semelhante, o *Gradient Boosting* também adiciona sequencialmente preditores a um conjunto, corrigindo os antecessores, porém em vez de ajustar os pesos da instância a cada interação, esse método tenta ajustar o preditor novo aos erros residuais cometidos pelo preditor anterior (GÉRON, 2019).

Figura 7 – Método de Boosting.



Fonte: Adaptado de (Gaurav Singhal, 2020)

### 3 TRABALHOS RELACIONADOS

A utilização de demoduladores a base de aprendizado de máquina para os mais diversos sistemas de comunicação vêm se tornando tema de vários trabalhos publicados nos últimos anos, isso não é diferente para sistemas que utilizam a comunicação por luz visível. Sendo assim, foi feita uma revisão literária em busca de trabalhos semelhantes, que utilizam diferentes modulações ou diferentes algoritmos de aprendizado de máquina.

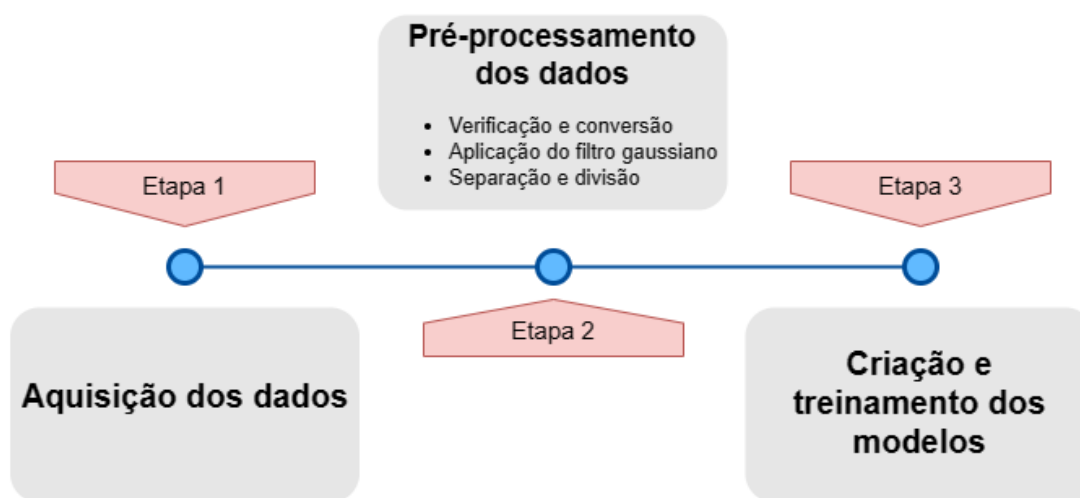
Após esta revisão literária, diferentes abordagens de demodulação de sinais de comunicação via aprendizado de máquina foram encontrados. Selecionaram-se trabalhos a partir de 2018, com as seguintes palavras-chave: *Signal demodulation*, *VLC*, *Machine Learning*. Na lista abaixo estão elencados os principais trabalhos:

- Os autores Walter, Khadr e Elgala (2019), propõem a criação de um *Autoencoder* convolucional para a demodulação de sinais, utilizando a técnica *Orthogonal frequency-division multiplexing (OFDM)*. Para uma razão sinal-ruído de 10dB, a rede alcançou a acurácia de 100% para a modulação 16-QAM e 99% para a modulação 64-QAM.
- No artigo de Ma et al. (2019), diversas modulações e demoduladores a base de algoritmos de aprendizado de máquina foram propostos, porém, para a modulação OOK, o algoritmo que obteve a melhor acurácia foi uma versão do *AdaBoost*, com o algoritmo *K-Nearest Neighbors* sendo utilizado como classificador fraco, alcançando 96% de acurácia em uma distância de 140 cm do emissor.
- No trabalho de Velu et al. (2021) foi proposta uma rede neural para a demodulação *Carrierless amplitude-phase (CAP)*. A rede neural do tipo *Extreme Learning Machine (ELM)* obteve 92.4% de acurácia quando submetido a uma razão sinal-ruído de 10dB.

## 4 MÉTODO PROPOSTO

Este capítulo procura detalhar o método proposto para a realização do trabalho. A figura 8 apresenta de forma simplificada o método desenvolvido. Na etapa 1 é abordado a aquisição dos dados. Na etapa 2 as formas de pré-processamento e aplicação de filtros. Por fim, o processo de treinamento dos algoritmos é descrito na etapa 3.

Figura 8 – Método proposto para o desenvolvimento do trabalho.



Fonte: Próprio autor.

### 4.1 FERRAMENTAS UTILIZADAS

Para o desenvolvimento do trabalho, foi elaborado um programa na linguagem de programação *Python*, que contempla todas as etapas do método proposto, desde a aquisição dos dados, até os resultados dos modelos de aprendizado de máquina. A escolha da linguagem se deve ao fato do seu grande uso e consequentemente a grande variedade de bibliotecas disponíveis para o tratamento de dados, criação e treinamento de modelos. As bibliotecas utilizadas estão listadas na tabela 2.

O ambiente de execução utilizado foi o *Google Colaboratory*, ambiente em nuvem desenvolvido pela *Google*. Foi escolhido pela praticidade, facilidade de compartilhamento e por ser executado na web. Além disso, uma máquina virtual com 12 GB de memória RAM e 107 GB de armazenamento é disponibilizado de forma gratuita e sem necessidade de nenhuma configuração prévia pelo usuário.

Tabela 2 – Bibliotecas utilizadas.

Biblioteca	Utilização
<i>NumPy</i>	Manipulação numérica e de vetores
<i>Gdown</i>	<i>Download</i> de arquivos do <i>Google Drive</i>
<i>SciPy</i>	Conversão de arquivos <i>.mat</i> e filtro Gaussiano
<i>SkLearn</i>	Divisão do conjunto de dados, algoritmos de aprendizado de máquina e acurácia
<i>Matplotlib</i>	Visualização dos resultados

Fonte: Próprio Autor.

## 4.2 AQUISIÇÃO DOS DADOS

Conforme citado na subseção 1.2.1, os dados utilizados neste trabalho foram obtidos através de um conjunto de dados público e disponibilizado por Ma et al. (2019).

Além disso, das oito diferentes modulações disponíveis, este trabalho abordará apenas a modulação OOK. E dos quatro diferentes números de amostras possíveis, e apenas os valores de 40 e 80 amostras serão abordados.

Nesta etapa inicial, uma cópia do conjunto de dados disponibilizado foi hospedado no *Google Drive*. Este processo foi feito para a utilização da biblioteca *Gdown*, que facilita o *download* dos dados para o ambiente do *Google Colaboratory*.

## 4.3 PRÉ-PROCESSAMENTO DOS DADOS

Na etapa de pré-processamento foram aplicadas diferentes técnicas para que os dados estejam íntegros e limpos no algoritmo de aprendizado de máquina. Segundo (KOTSIANTIS; KANELLOPOULOS; PINTELAS, 2006), esta etapa de remoção de ruídos e dados inúteis é uma das tarefas mais difíceis e com impacto significativo no desempenho dos modelos de aprendizado de máquina.

### 4.3.1 Verificação e conversão dos dados


A primeira parte do Pré-Processamento consiste na verificação dos dados após a transferência para o ambiente de execução. Os dados originais se encontram no formato *.mat*, sendo necessário o uso do módulo *loadmat* da biblioteca *SciPy* para a conversão em vetores do *NumPy*. Após a conversão, não foi necessário o uso de métodos para a limpeza dos dados, pois o conjunto não apresenta inconsistências ou valores vazios.



### 4.3.2 Aplicação de filtros


Com os dados convertidos, notou-se que sinais que representam a mesma saída, ou rótulo, em maiores distâncias apresentavam valores diferentes, esse fato pode ter ocorrido devido a ruídos ou imprecisões ocasionadas na obtenção desses dados. O gráfico 1 demonstra a diferença de sinais que deveriam ser iguais, porém são alterados devido à distância da medição.

Gráfico 1 – Sinais na distância 0 cm e distância 140 cm.



Fonte: Próprio autor.

Gráfico 2 – Sinais filtrados na distância 0 cm e distância 140 cm.



Fonte: Próprio autor.

Conforme citado na seção 1.2, o filtro gaussiano se mostrou uma boa alternativa para a redução de ruído, então, um filtro Gaussiano de grau 3 foi aplicado nos sinais, é possível verificar o sinal filtrado em preto no gráfico 2.

### 4.3.3 Separação e divisão dos dados

Conforme descrito na seção 4.2, o conjunto de dados possui os mesmos rótulos para diferentes distâncias, ou seja, é possível treinar um algoritmo de aprendizado de máquina para cada distância, ou simplesmente unir as diferentes distâncias e treinar um algoritmo de propósito geral. Ambos os casos serão abordados neste trabalho e exigem uma diferente separação dos dados.

No primeiro caso, onde ocorre um treinamento para cada distância, é necessário, de forma iterativa, percorrer cada distância fazendo a separação entre dados de treino e teste, e treinando os algoritmos nos diferentes dados de treino. Este processo se torna simplificado, pois o conjunto de dados original já dispõe as distâncias de forma separada. Nesta abordagem haverá mais treinamentos, porém com menor número de dados por treinamento.

No segundo caso, é feita a união dos valores de todas as distâncias de forma ordenada em um único conjunto para separá-lo em dados de treino e teste, para finalmente treinar o algoritmo nos dados de treino. Nesta abordagem haverá um único treinamento, porém com um número muito maior de dados.

Portanto, duas abordagens diferentes são propostas, onde cada abordagem possui dois possíveis casos para cada algoritmo de aprendizado de máquina, sendo eles:

- Abordagem 1:
  - Conjunto de dados subdividido por distâncias sem filtro gaussiano.
  - Conjunto de dados subdividido por distâncias com filtro gaussiano.
- Abordagem 2:
  - Conjunto de dados com todas as distâncias sem filtro gaussiano.
  - Conjunto de dados com todas as distâncias com filtro gaussiano.

Em todas as abordagens os dados são divididos em uma proporção 70/30, sendo 70% para treino e 30% para teste. Essa divisão oferece um número balanceado de dados para treino e teste, aumentando as chances do algoritmo abranger todos os possíveis casos.

## 4.4 CRIAÇÃO E TREINAMENTO DOS MODELOS

Conforme citado na seção 1.2, foram utilizados quatro diferentes algoritmos para a criação dos demoduladores.

O objetivo nesta etapa é verificar e comparar qual algoritmo possui o melhor desempenho como demodulador. Para extrair o melhor de cada algoritmo, diversas variações de hiper parâmetros foram testadas. Considerando o desempenho dos classificadores e as limitações do ambiente de execução, os hiper parâmetros alterados estão descritos na tabela 3, os hiper parâmetros não citados são definidos por padrão pela biblioteca *Sklearn*.

Tabela 3 – Hiper parâmetros dos algoritmos utilizados.

Algoritmo	Classificador base	Função base	número de classificadores base
Árvore de decisão	N.A	Entropia	N.A
Floresta Aleatória	Árvore de decisão	Entropia	25
<i>Gradient Boosting</i>	Árvore de decisão	Entropia	25
<i>AdaBoost</i>	Árvore de decisão	Entropia	25

Fonte: Próprio Autor.

A métrica utilizada para comparação de desempenho entre os diferentes modelos é a acurácia.

## 5 RESULTADOS EXPERIMENTAIS

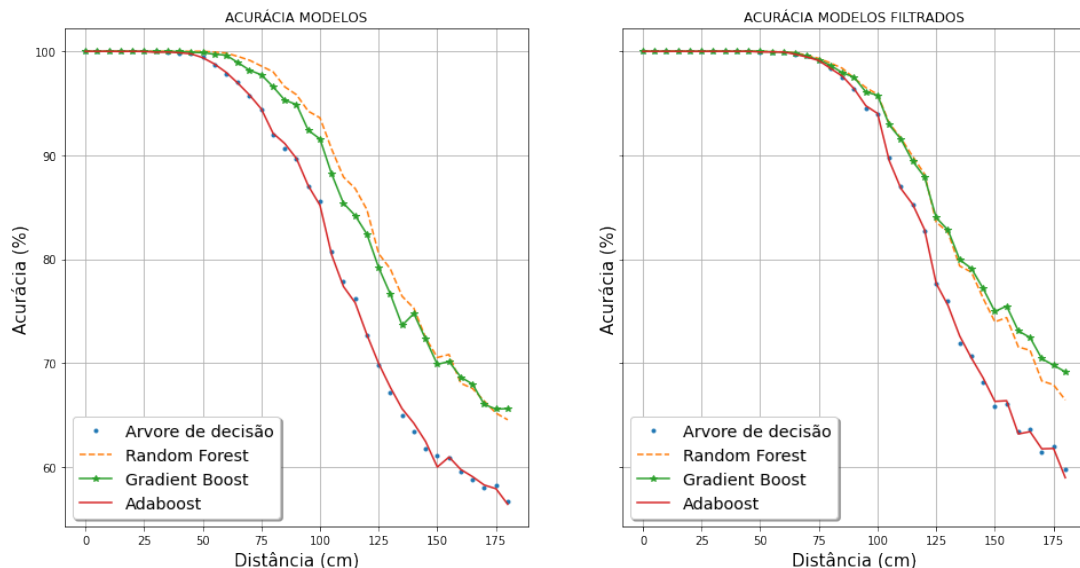
Este capítulo visa apresentar e comparar os resultados experimentais obtidos aplicando o método proposto e será dividido em três seções, duas para as diferentes abordagens desenvolvidas, e uma para uma breve discussão final.

Nas duas primeiras seções, dois gráficos serão desenvolvidos, com o intuito de mostrar a acurácia obtida nas diferentes distâncias com 40 e 80 amostras. Além disso, para uma melhor visualização dos valores em porcentagem, serão criadas tabelas com alguns valores contidos nos gráficos. Por fim, na última seção, tabelas serão criadas para a comparação e verificação dos resultados obtidos nas abordagens de uma maneira geral.

### 5.1 RESULTADOS ABORDAGEM 1

Com os conjuntos de dados da modulação OOK com 40 e 80 amostras particionados, alguns padrões podem ser notados. Pelo fato do conjunto estar dividido por distâncias, cada modelo gerado consegue criar uma abordagem matemática que melhor se adapta à razão entre sinal e ruído de sua distância específica.

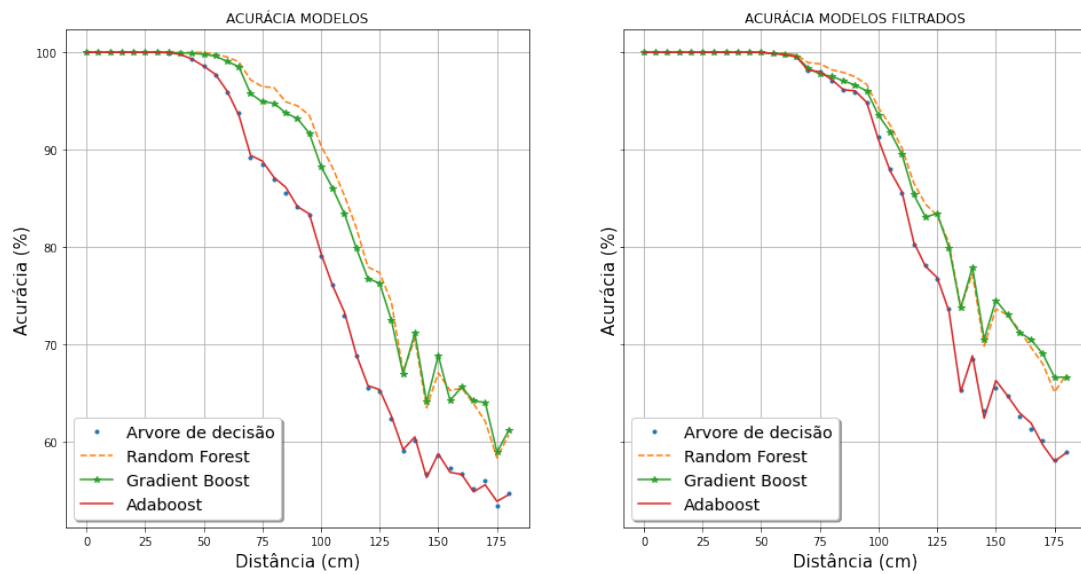
Gráfico 3 – Acurácia dos modelos com 40 amostras abordagem 1.



Fonte: Próprio autor.

Visualizando o gráfico 3 e o gráfico 4, que representam as acurácias dos modelos criados para a distância 0 cm até a distância 180 cm, nota-se que, conforme o aumento da distância, há uma queda na acurácia, esse comportamento se faz presente independente do número de amostras. Essa constatação sinaliza que, com o aumento da distância, o

Gráfico 4 – Acurácia dos modelos com 80 amostras abordagem 1.



Fonte: Próprio autor.

algoritmo começa a ter dificuldades em encontrar padrões nos ruídos inseridos nos sinais.

Além disso, é possível notar que *Random Forest* e *Gradient Boosting* obtiveram métricas semelhantes e superiores aos demais algoritmos em todos os conjuntos de dados desta seção.

Tabela 4 – Acurácia na distância 100 cm com 40 amostras abordagem 1.

Algoritmo	Sem filtro	Com filtro
<i>Random Forest</i>	93,70%	95,90%
<i>Gradient Boosting</i>	91,56%	95,77%
<i>AdaBoost</i>	85,21%	94,25%
<i>Árvore de decisão</i>	85,05%	93,92%

Fonte: Próprio Autor.

Tabela 5 – Acurácia na distância 100 cm com 80 amostras abordagem 1.

Algoritmo	Sem filtro	Com filtro
<i>Random Forest</i>	90,10%	94,30%
<i>Gradient Boosting</i>	88,29%	93,53%
<i>AdaBoost</i>	78,73%	91,01%
<i>Árvore de decisão</i>	78,97%	91,39%

Fonte: Próprio Autor.

Para uma melhor visualização do gráfico 3, a tabela 4 expõe a acurácia de cada algoritmo no conjunto com 40 amostras, na distância de 100 cm. Verifica-se que *Random*

*Forest* obteve a melhor acurácia nesta distância. Outro fator importante é que com a aplicação do filtro, todos os algoritmos têm sua acurácia aumentada, em especial árvore de decisão e *AdaBoost*, onde o filtro aumentou em mais de 8% a acurácia.

De forma análoga à tabela 4, a tabela 5 apresenta os valores das acurácias na distância 100cm, porém no conjunto com 80 amostras. Novamente, a acurácia foi aumentada em todos os casos, principalmente nos algoritmos árvore de decisão e *AdaBoost*, em que houve o aumento de mais de 12% na acurácia.

No gráfico 3 e no gráfico 4, foi possível verificar que o filtro consegue, com sucesso, elevar a acurácia de todos os modelos propostos, até mesmo aqueles que tiveram acurácias menores.

Portanto, é possível inferir que o filtro facilita a predição do modelo, principalmente em distâncias maiores, suavizando o ruído dos sinais. Essa afirmação pode ser visualizada na tabela 4 e na tabela 5, onde o filtro elevou consideravelmente a acurácia dos modelos na distância 100 cm.

Tabela 6 – Melhora na acurácia com 40 amostras abordagem 1.

Algoritmo	70 cm	100 cm	150 cm	180 cm
<i>Random Forest</i>	0,67%	2,20%	3,60%	4,00%
<i>Gradient Boosting</i>	1,36%	4,20%	5,08%	3,53%

Fonte: Próprio Autor.

Tabela 7 – Melhora na acurácia com 80 amostras abordagem 1.

Algoritmo	70 cm	100 cm	150 cm	180 cm
<i>Random Forest</i>	1,51%	4,20%	6,44%	6,75%
<i>Gradient Boosting</i>	2,64%	5,23%	5,67%	5,48%

Fonte: Próprio Autor.


Para visualizar a influência do filtro nos resultados, a tabela 6 e a tabela 7 apresentam, para as distâncias 70 cm, 100 cm, 150 cm e 180 cm, o impacto do filtro na melhora da acurácia nos dois algoritmos com melhor desempenho, para 40 e 80 amostras, respectivamente.

## 5.2 RESULTADOS ABORDAGEM 2

Repetindo os procedimentos da seção anterior, porém passando como entrada os sinais de todas as distâncias, visando a criação de um demodulador adaptável a qualquer distância, verificou-se que os algoritmos não conseguiram encontrar padrões da mesma

forma que na seção anterior nos sinais e seus ruídos em diferentes distâncias. Como resultado, acurácias inferiores se comparadas com as da seção anterior foram obtidas.

Gráfico 5 – Acurácia dos modelos com 40 amostras abordagem 2.



Fonte: Próprio autor.

Assim como na seção anterior, a figura 5 e a figura 6, representam as acurácias do modelo criado para a distância 0 cm até a distância 180 cm, nos conjuntos de 40 e 80 amostras, respectivamente.

Visualizando essas figuras, notam-se diversas oscilações nas diferentes distâncias, com gráficos bem menos suaves se comparados com os da seção anterior.

De forma análoga aos resultados da seção anterior, na maior parte dos casos, os algoritmos *Random Forest* e *Gradient Boosting* obtiveram as melhores métricas.

Visualizando a tabela 8, que representa a acurácia dos modelos na distância 100 cm para 40 amostras, verifica-se que, diferente da seção anterior, nesta abordagem o algoritmo *Random Forest* obteve uma leve queda na acurácia na distância 100 cm, além dos valores de aumento de acurácia dos outros algoritmos não serem tão significativos.


Tabela 8 – Acurácia na distância 100 cm com 40 amostras abordagem 2.

Algoritmo	Sem filtro	Com filtro
<i>Random Forest</i>	92,84%	92,27%
<i>Gradient Boosting</i>	91,16%	94,73%
<i>AdaBoost</i>	82,30%	84,37%
<i>Árvore de decisão</i>	82,59%	84,64%

Fonte: Próprio Autor.

Além disso, de forma semelhante à tabela 8, a tabela 9 também verifica a acurácia dos modelos na distância 100 cm, porém para 80 amostras. Neste caso, todos os algo-

Gráfico 6 – Acurácia dos modelos com 80 amostras abordagem 2.



Fonte: Próprio autor.

Tabela 9 – Acurácia na distância 100 cm com 80 amostras abordagem 2.

Algoritmo	Sem filtro	Com filtro
<i>Random Forest</i>	90,50%	92,91%
<i>Gradient Boosting</i>	87,76%	93,55%
<i>AdaBoost</i>	76,46%	85,20%
<i>Árvore de decisão</i>	74,79%	84,09%

Fonte: Próprio Autor.

ritmos obtiveram as acurácias melhoradas com o uso do filtro, em destaque os algoritmos árvore de decisão e *AdaBoost*, que o aumento foi superior a 9%

Novamente, visualizando a figura 5 e a figura 6, verifica-se que o filtro eleva a acurácia dos modelos propostos na maior parte dos casos, até mesmo dos modelos que tiveram acurácias menores.

Tabela 10 – Melhora na acurácia com 40 amostras abordagem 2.

Algoritmo	70 cm	100 cm	150 cm	180 cm
<i>Random Forest</i>	0,10%	-0,57%	2,57%	1,11%
<i>Gradient Boosting</i>	-0,13%	3,59%	4,89%	1,39%

Fonte: Próprio Autor.

Assim como na seção anterior, a tabela 10 e a tabela 11 mostram, para as distâncias 70 cm, 100 cm, 150 cm e 180 cm, o impacto do filtro na melhora da acurácia, para 40 e 80 amostras, respectivamente.



Tabela 11 – Melhora na acurácia com 80 amostras abordagem 2.

Algoritmo	70 cm	100 cm	150 cm	180 cm
<i>Random Forest</i>	1,78%	2,40%	4,10%	4,42%
<i>Gradient Boosting</i>	4,54%	5,79%	5,13%	5,94%

Fonte: Próprio Autor.

### 5.3 DISCUSSÃO FINAL

Verificando os resultados obtidos, fica claro que quando o algoritmo é treinado para uma distância específica, independente do número de amostras, obtêm-se melhores resultados se comparado com o algoritmo treinado para todas as distâncias.

Além disso, o filtro gaussiano se mostrou eficiente em ambas abordagens, aumentando a acurácia em todos os casos da abordagem 1 e em grande parte dos casos na abordagem 2. Essa melhora na abordagem 2 se mostrou presente principalmente nas distâncias maiores, onde os casos que o filtro influenciou de forma negativa eram de distâncias inferiores a 110 cm.

A tabela 12 e a tabela 15 têm como base o algoritmo *Random Forest*, e o algoritmo *Gradient Boosting*, respectivamente, em algumas distâncias para comparar o resultado das diferentes abordagens no conjunto de 40 amostras.

Tabela 12 – Comparação das abordagens com o algoritmo *Random Forest* 40 amostras.

Algoritmo	50 cm	100 cm	150 cm	180 cm
Abordagem 1 sem filtro	100%	93,70%	70,23%	63,78%
Abordagem 1 com filtro	100%	95,90%	73,83%	67,79%
Abordagem 2 sem filtro	99,05%	92,84%	70,65%	63,35%
Abordagem 2 com filtro	97,17%	92,27%	73,23%	64,46%

Fonte: Próprio Autor.

Tabela 13 – Comparação das abordagens com o algoritmo *Gradient Boosting* 40 amostras.

Algoritmo	50 cm	100 cm	150 cm	180 cm
Abordagem 1 sem filtro	99,86%	91,56%	69,88%	65,62%
Abordagem 1 com filtro	100%	95,77%	74,96%	69,15%
Abordagem 2 sem filtro	99,62%	91,16%	67,72%	60,75%
Abordagem 2 com filtro	99,17%	94,73%	72,62%	62,15%

Fonte: Próprio Autor.

Analogamente às tabelas 12 e 13, a tabela 14 e a tabela 15 apresentam os resultados de todas as abordagens desenvolvidas, em algumas distâncias, para os algoritmos *Random Forest* e *Gradient Boosting* respectivamente, para 80 amostras.

Tabela 14 – Comparação das abordagens com o algoritmo *Random Forest* 80 amostras.

Algoritmo	50 cm	100 cm	150 cm	180 cm
Abordagem 1 sem filtro	99,96%	90,10%	67,67%	59,96%
Abordagem 1 com filtro	100,0%	94,30%	74,12%	66,71%
Abordagem 2 sem filtro	98,06%	90,50%	68,97%	62,52%
Abordagem 2 com filtro	98,65%	92,91%	73,08%	66,95%

Fonte: Próprio Autor.

Tabela 15 – Comparação das abordagens com o algoritmo *Gradient Boosting* 80 amostras.

Algoritmo	50 cm	100 cm	150 cm	180 cm
Abordagem 1 sem filtro	99,79%	88,29%	68,87%	61,17%
Abordagem 1 com filtro	99,98%	93,53%	74,54%	66,66%
Abordagem 2 sem filtro	98,82%	87,76%	67,37%	60,52%
Abordagem 2 com filtro	97,76%	93,55%	72,50%	66,46%

Fonte: Próprio Autor.

Analisando o gráfico 5 e o gráfico 6, nota-se que o algoritmo treinado na abordagem 2 possui menos oscilações e mantém-se consistente por maiores distâncias com o aumento do número de amostras, um indício de que caso mais dados fossem adicionados ou a complexidade do número de amostras fosse superior, estaria mais próximo do algoritmo treinado de forma específica. O que torna os resultados promissores para trabalhos futuros.

## 6 CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS

Este trabalho teve como objetivo o desenvolvimento de diferentes algoritmos e abordagens para a construção de um demodulador para sinais de comunicação por luz visível através de aprendizado de máquina.

Para isso, inicialmente houve o levantamento de trabalhos relacionados com a demodulação de sinais de telecomunicações via aprendizado de máquina. Além da identificação de algoritmos que melhor se encaixassem com o propósito do trabalho. Após, houve o desenvolvimento do método, composto por 3 etapas, sendo elas: a aquisição dos dados, o pré-processamento dos dados e o treinamento e teste dos algoritmos. Os algoritmos utilizados para a obtenção dos resultados foram: árvores de decisão, Florestas Aleatórias, *Gradient Boosting* e *AdaBoost*.

Através dos resultados obtidos, verificou-se que em todos os casos, os demoduladores com base nos algoritmos *Random Forest* e *Gradient Boosting* obtiveram acurácias superiores aos demais, chegando a alcançar a acurácia, mesmo 100 cm longe do emissor, de 95,90% e 95,77%, respectivamente.

Além de que, a utilização do filtro gaussiano teve um impacto positivo na acurácia dos modelos. Os algoritmos obtiveram melhores métricas quando treinados de forma específica a cada distância, porém, a ideia de um algoritmo de propósito geral merece atenção especial, pois apenas um modelo é criado, diferente do primeiro caso, onde um modelo é criado para cada distância.

Por fim, durante o desenvolvimento do trabalho, diversos pontos de melhoria para trabalhos futuros foram encontrados, como a exploração de algoritmos de aprendizado de máquina mais robustos, a utilização de *ensembles* com outros algoritmos-base, a criação de um conjunto de dados com maior controle de ruídos e maior número de amostras, assim como uma abordagem diferente na filtragem dos sinais.

## REFERÊNCIAS

- AMRAN, N. A. et al. Deep learning based signal detection for ofdm vlc systems. In: **2020 IEEE International Conference on Communications Workshops (ICC Workshops)**. Dublin, Ireland: IEEE, 2020. p. 1–6.
- ARNON, S. **Visible Light Communication**. Cambridge: Cambridge University Press, 2015. 224 p.
- BREIMAN, L. Random forests. **Machine Learning**, v. 45, p. 5–32, 2001.
- CHEN, W.-K. **The Electrical Engineering Handbook**. US: Elsevier Academic Press, 2005. 1208 p.
- CHI, N. et al. Visible light communication in 6g: Advances, challenges, and prospects. **IEEE Vehicular Technology Magazine**, v. 15, n. 4, p. 93–102, 2020.
- CHOLLET, F. **Deep Learning with Python**. US: Manning, 2017. 384 p.
- Gaurav Singhal. **Ensemble Methods in Machine Learning: Bagging Versus Boosting**. Pluralsight, 2020. Acesso em 30 jan. 2023. Disponível em: <<https://www.pluralsight.com/guides/ensemble-methods:-bagging-versus-boosting>>.
- GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and Tensorflow**. US: O'Reilly Media, 2019. 856 p.
- HARRISON, M. **Machine Learning Pocket Reference: Working with Structured Data in Python**. US: O'Reilly Media, 2019. 320 p.
- ITO, K.; XIONG, K. Gaussian filters for nonlinear filtering problems. **IEEE Transactions on Automatic Control**, v. 45, n. 5, p. 910–927, 2000.
- JAIN, A. et al. Overview and importance of data quality for machine learning tasks. In: **Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery Data Mining**. New York, NY, USA: Association for Computing Machinery, 2020. p. 3561–3562.
- KINGSFORD, C.; SALZBERG, S. L. What are decision trees? **Nature Biotechnology**, v. 26, p. 1011–1013, 2008.
- Kiran Bhageshpur. **Data Is The New Oil And That's A Good Thing**. Forbes, 2019. Acesso em 30 jan. 2023. Disponível em: <<https://www.forbes.com/sites/forbestechcouncil/2019/11/15/data-is-the-new-oil-and-thats-a-good-thing/?sh=7e886ef57304>>.
- KOTSIANTIS, S.; KANELLOPOULOS, D.; PINTELAS, P. Data preprocessing for supervised learning. **International Journal of Computer Science**, v. 1, p. 111–117, 2006.
- MA, S. et al. Signal demodulation with machine learning methods for physical layer visible light communications: Prototype platform, open dataset, and algorithms. **IEEE Access**, v. 7, p. 30588–30598, 2019.

MATHEUS, L. et al. Comunicação por luz visível: Conceitos, aplicações e desafios. In: SIMPÓSIO BRASILEIRO DE REDES DE COMPUTADORES E SISTEMAS DISTRIBUÍDOS, 35. **Livro de Minicursos**. Belém, Pará: Sociedade Brasileira de Computação, 2017. p. 247–296.

NANDI, A.; PAL, A. K. **Interpreting Machine Learning Models: Learn Model Interpretability and Explainability Methods**. India: Apress, 2021. 368 p.

NDJIONGUE, A. R.; FERREIRA, H. C.; NGATCHED, T. M. N. **Wiley Encyclopedia of Electrical and Electronics Engineering**. New Jersey: John Wiley Sons, Ltd, 2000. 880 p.

OLSON, J. E. **Data Quality: The Accuracy Dimension**. USA: Morgan Kaufmann, 2003. 312 p.

OPITZ, D.; MACLIN, R. Popular ensemble methods: An empirical study. **Journal of Artificial Intelligence Research**, v. 11, p. 169 – 198, 1999.

PRAVEENA, M.; JAIGANESH, V. A literature review on supervised machine learning algorithms and boosting process. **International Journal of Computer Applications**, v. 169, p. 32–35, 2017.

ROKACH, L. **Data Mining and Knowledge Discovery Handbook**. Boston: Springer, 2005. 1383 p.

SHI, Y. et al. A review of machine learning based techniques for demodulation. In: **2020 IEEE 9th Joint International Information Technology and Artificial Intelligence Conference (ITAIC)**. Chongqing, China: IEEE, 2020. v. 9, n. 9, p. 2292–2296.

VELU, P. et al. Deep learning neural network for cap modulation in visible light communication system. **Research Square**, v. 1, 2021.

WALTER, I.; KHADR, M. H.; ELGALA, H. Deep learning based optical camera communications. In: **OSA Advanced Photonics Congress (AP) 2019 (IPR, Networks, NOMA, SPPCom, PVLED)**. [S.l.]: Optica Publishing Group, 2019. p. SpTh3E.2.

YI, L.; LEE, S. G. Performance improvement of dimmable vlc system with variable pulse amplitude and position modulation control scheme. In: **2014 International Conference on Wireless Communication and Sensor Network**. Wuhan, China: IEEE, 2014. p. 81–85.

## **APÊNDICE A – CÓDIGOS DESENVOLVIDOS**

Todos os códigos desenvolvidos no desenvolvimento deste trabalho foram hospedados na plataforma GitHub, sendo o acesso possível através do link: **CÓDIGOS DESENVOLVIDOS POR LORENZO DONATTI**.